Sinais do treino alinhados por passo — HAR70+, CNN 1D, lote 128

Melhor configuração (= melhor com Muon)
muon η=0.01 wsd s0 (AdamW η=0.003)
F1 val = 0.697

Melhor sem Muon (confirmação e4)
sgd η=0.3 warmup_cosseno s0
F1 val = 0.696

Baseline (receita atual)
adam η=0.001 constante s0
F1 val = 0.673

Instável (divergiu)
nesterov η=1 warmup_cosseno s0
DIVERGIU no passo 82

Instável (colapsou: prevê uma classe só)
sgd η=1 warmup_cosseno s0
F1 val = 0.095

perda (CE ponderada)

treino (média em k=25)
validação

$\|\nabla\theta\mathcal{L}\|_2$ (pré-clipping)

máx. na janela de k passos
no passo registrado

$\|\theta\|_2$

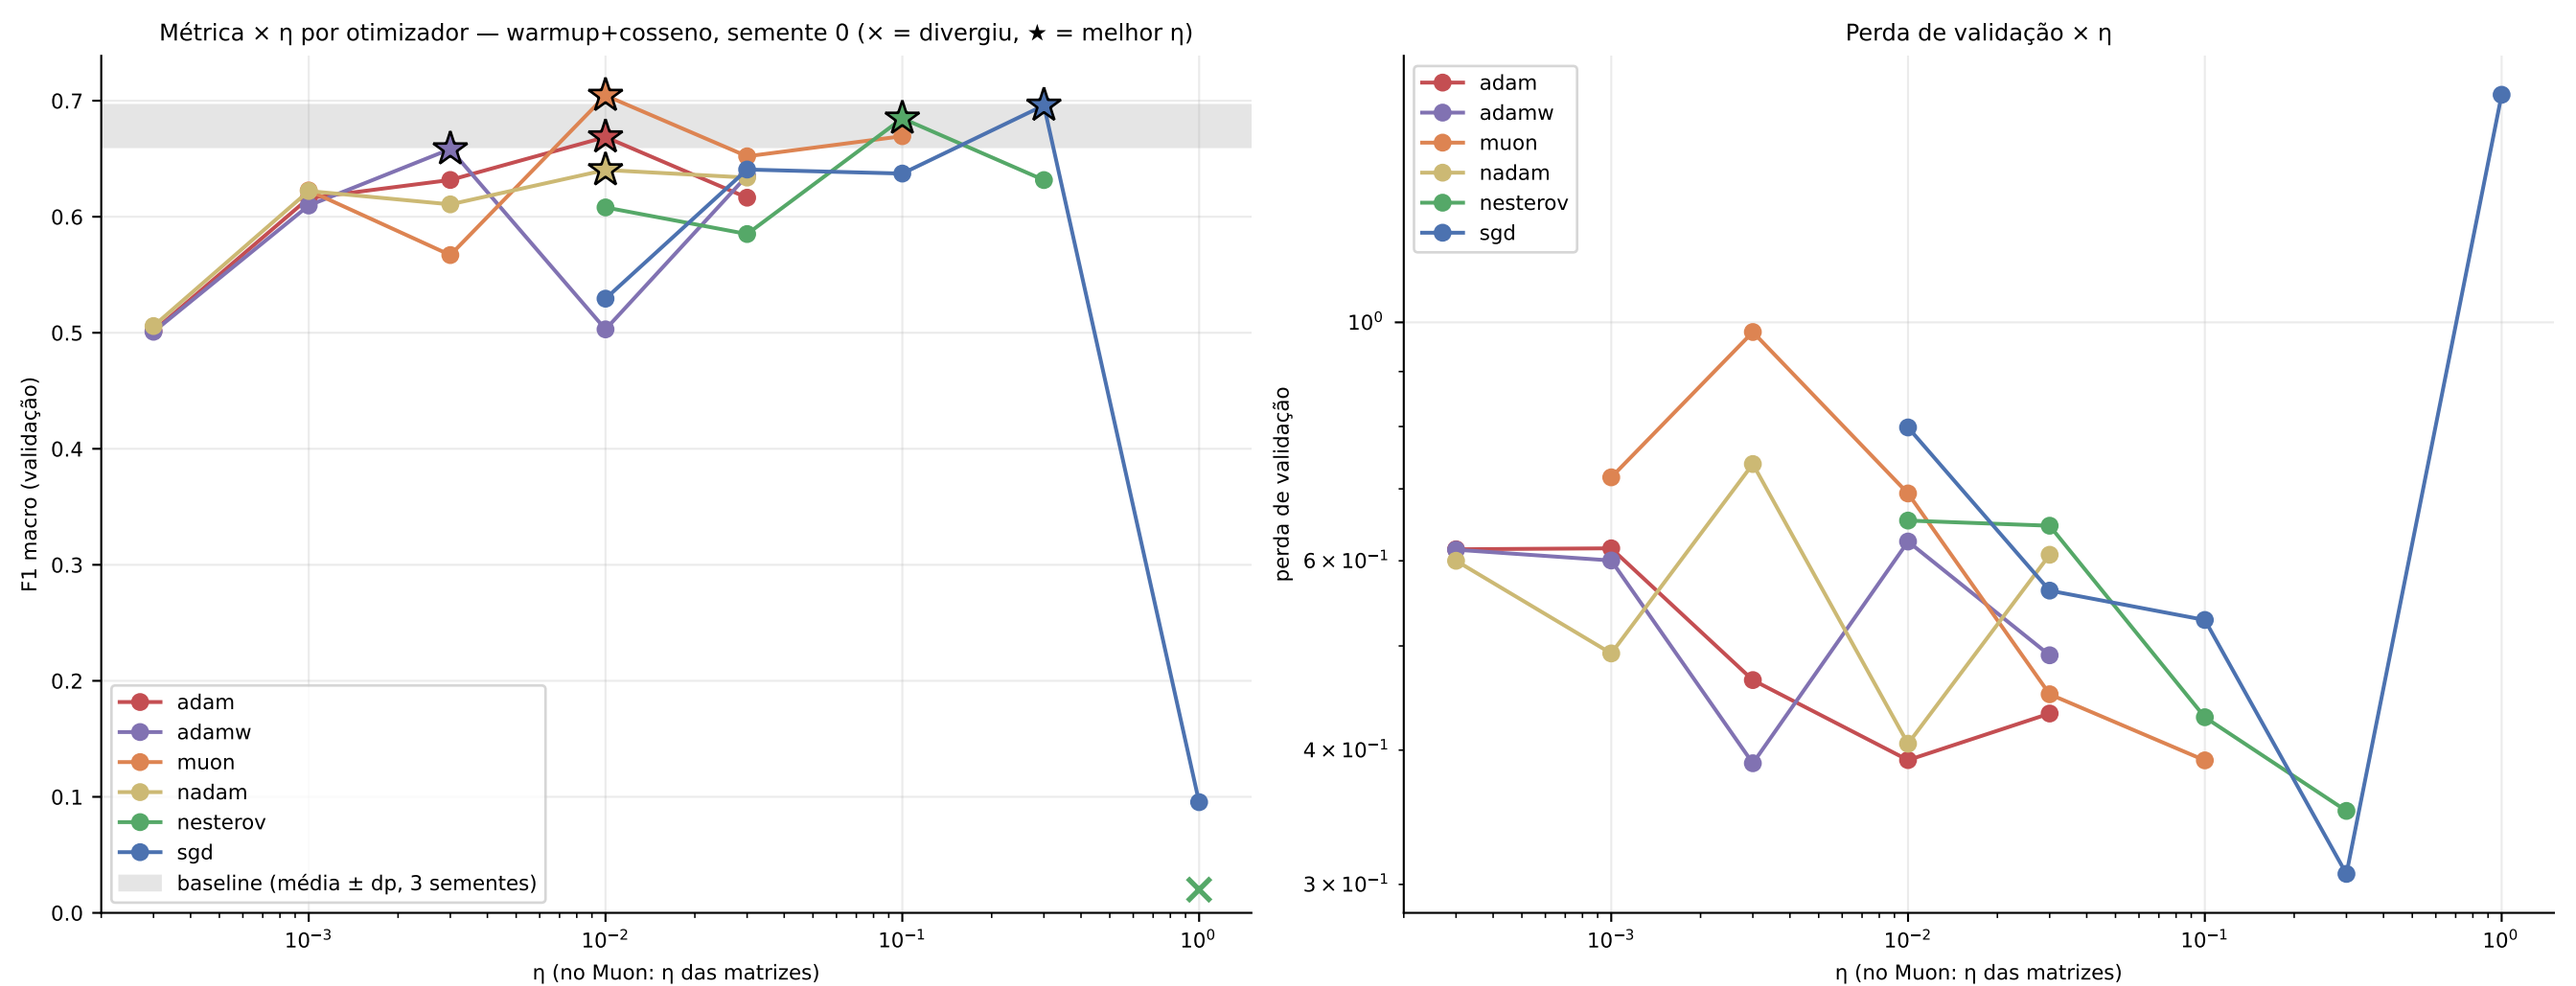
η_t

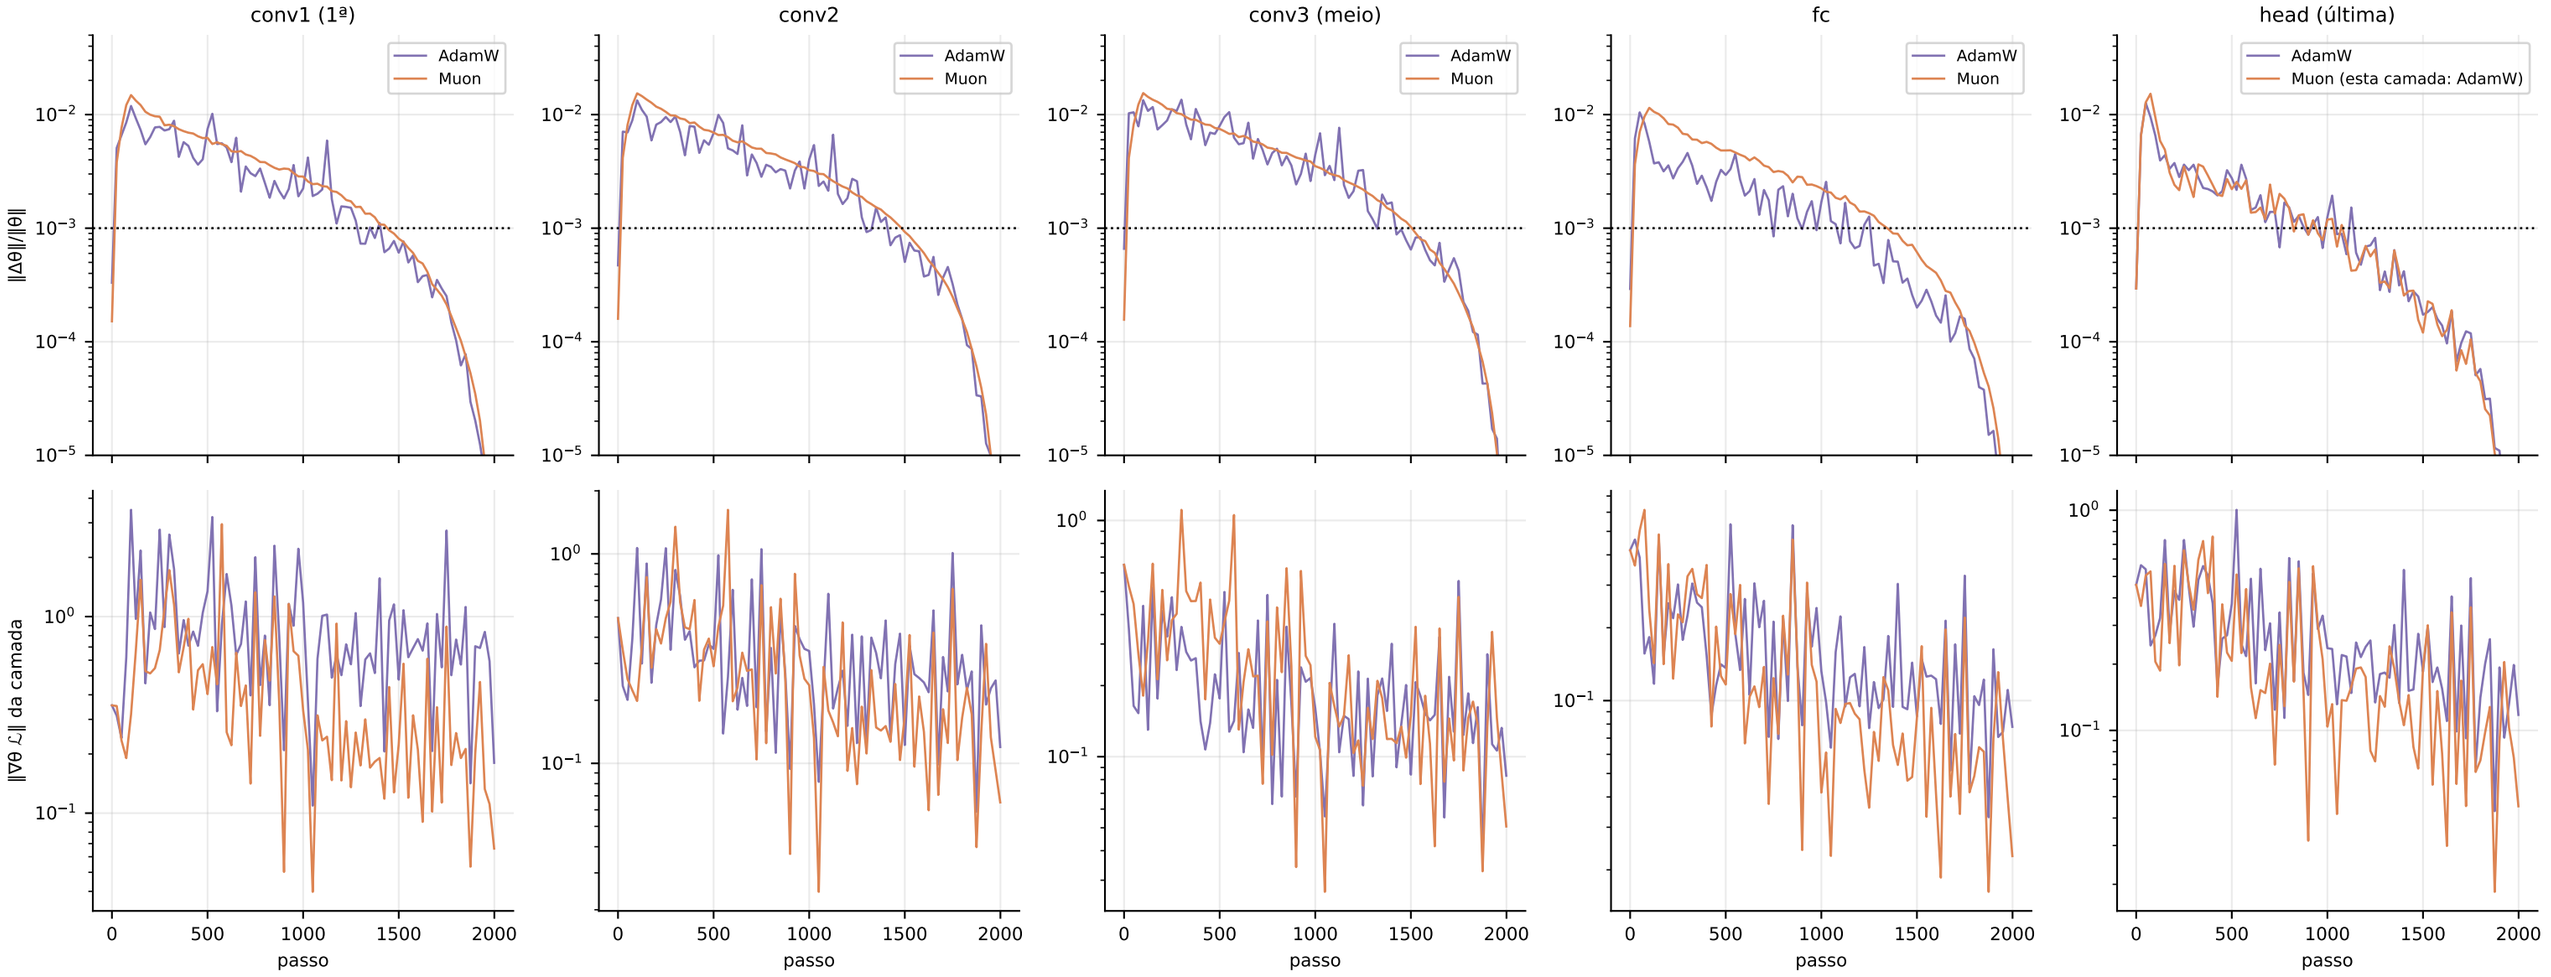
η (matrizes Muon)
η (parte AdamW)

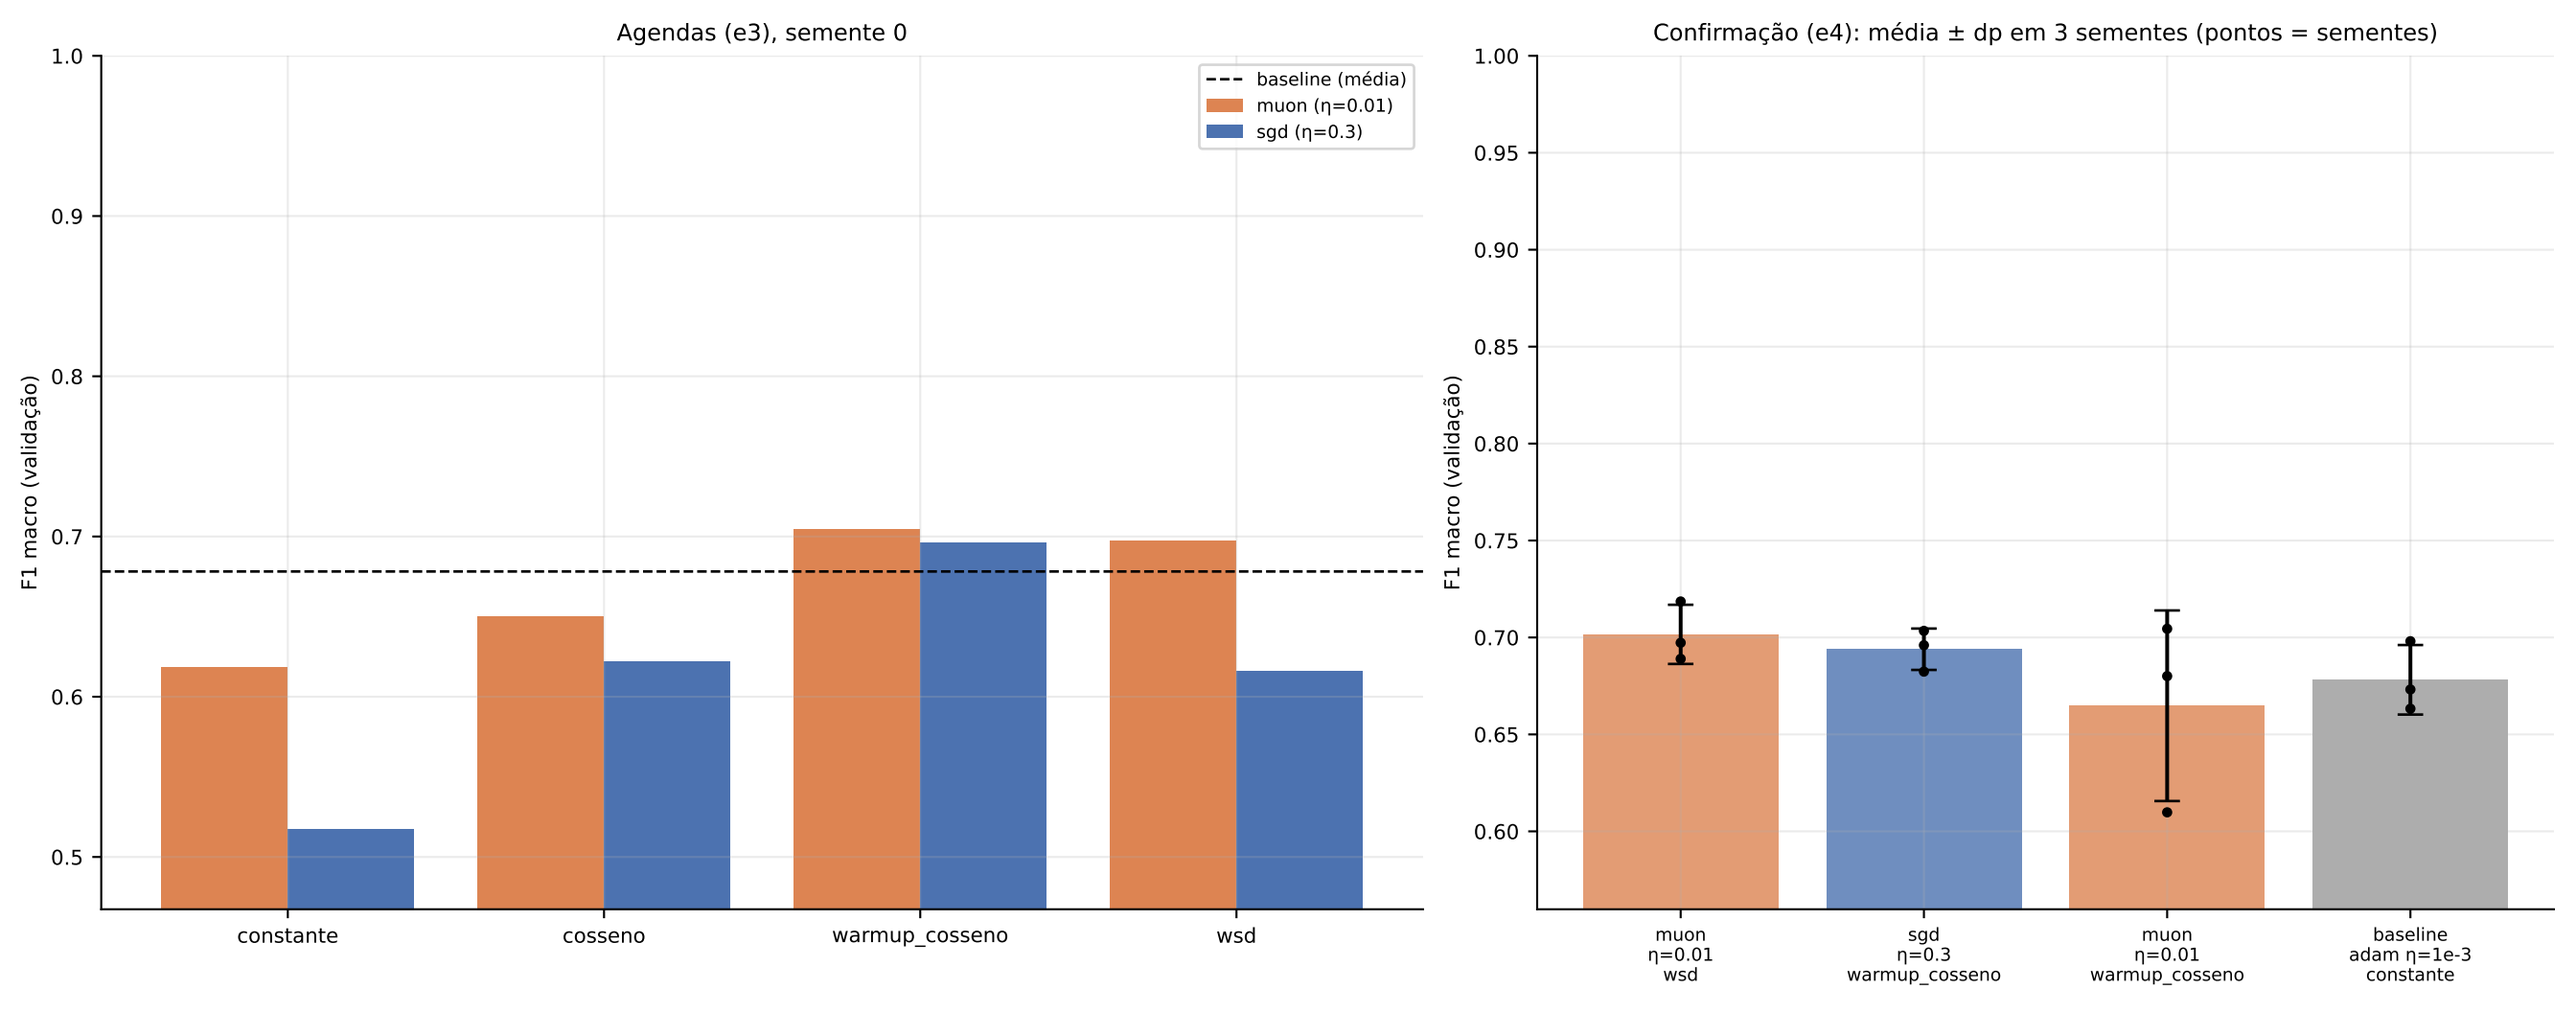
$\|\Delta\theta\|/\|\theta\|$ por camada
(linha: 10^{-3})

conv1 (1ª)
conv2
conv3 (meio)
fc
head (última)

passo


Métrica × η por otimizador — warmup+cosseno, semente 0 (× = divergiu, ★ = melhor η)
F1 macro (validação)
η (no Muon: η das matrizes)
adam
adamw
muon
nadam
nesterov
sgd
baseline (média ± dp, 3 sementes)
Perda de validação × η
perda de validação
η (no Muon: η das matrizes)


Razão de atualização e gradiente por camada — adamw η=0.003 warmup_cosseno s0 × muon η=0.01 warmup_cosseno s0 (AdamW η=0.003)
conv1 (1ª)
conv2
conv3 (meio)
fc
head (última)
AdamW
Muon
Muon (esta camada: AdamW)
‖Δθ‖/‖θ‖
‖∇θ ℒ‖ da camada
passo


Agendas (e3), semente 0
F1 macro (validação)
1.0
0.9
0.8
0.7
0.6
0.5
baseline (média)
muon (η=0.01)
sgd (η=0.3)
constante
cosseno
warmup_cosseno
wsd
Confirmação (e4): média ± dp em 3 sementes (pontos = sementes)
F1 macro (validação)
1.00
0.95
0.90
0.85
0.80
0.75
0.70
0.65
0.60
muon
η=0.01
wsd
sgd
η=0.3
warmup_cosseno
muon
η=0.01
warmup_cosseno
baseline
adam η=1e-3
constante