Desafio 3 — Receita vencedora na HAR70+: Muon + agenda WSD

Muon nas matrizes ocultas (η = 0,01) + AdamW no resto (η = 0,003) · WSD: warmup 5%, η constante, decaimento linear nos 20% finais

F1 macro na validação (3 sementes)

0,702 ± 0,015 Muon + WSD (vencedor)

0,694 ± 0,011 SGD η=0.3 + warmup+cosseno

0,678 ± 0,018 baseline: Adam η=10^{-3} constante

Ganho +0,024: maior que o desvio entre sementes de cada um,
mas com 3 sementes é evidência fraca (Welch p ≈ 0,16). SGD empata com o Muon.

Teste (usado uma vez)

0,765 ± 0,014 vs 0,634 ± 0,061 (baseline)

o ganho vem quase todo das classes de escada (9 janelas cada no teste)

Por que vence — lido nos sinais

1. η constante nunca assenta: na baseline ‖g‖ fica ≈ 1,4 e ruidoso até o último passo
   → o ponto final é sorteado no fundo do vale (teste varia 0,57–0,69 entre sementes).

2. Muon + WSD desce mais fundo: ‖g‖ ≈ 0,5 (3× menor) e perda de treino 0,05 vs 0,11; o decaimento final assenta. Agenda constante foi a pior para Muon (0,62) e SGD (0,52).

3. Com BatchNorm, ‖θ‖ do Muon cresce 11 → 28 e a razão de atualização cai de 10^{-2} para $4 \cdot 10^{-3}$ com η fixo: um decaimento implícito durante a fase estável.

4. Limite: a perda de validação chega ao mínimo cedo (mediana: passo 700) e termina ~25% acima
   → sobreajuste entre participantes, não instabilidade. Próximo: regularização / parada antecipada.

